8INF912 - Sujet spécial en Machine Learning

Food Recognition

Université du Québec à Chicoutimi

Georges Cosson
11/06/2019

Présentation du projet

Le but de ce projet est de reconnaitre les aliments d'une assiette à partir d'une photographie de ceux-ci. Il s'inscrit dans un cadre plus large visant à fournir un outil aux diabétiques leur permettant d'avoir une estimation des glucides de leur repas à partir d'une simple photographie depuis leur téléphone.

L'intégralité du code est disponible ici.

Travail réalisé

Découverte de la détection d'objets

Découverte

- Recherche de datasets de nourriture et d'aliments
- Recherches et compréhension des différents algorithmes
- Familiarisation avec le dataset Food-101

Première expérience

- Mise en place d'une instance IBM Cloud Storage
- Upload d'une partie du dataset sur celle-ci
- Utilisation de l'outil Cloud Annotation Tool pour annoter ces images
- Entrainement d'un modèle SSD MobileNet sur une instance IBM Cloud Computing
- Récupération du modèle
- Installation et configuration d'une application ReactJS pour tester le résultat sur ma webcam

Bilan

Le dataset était beaucoup trop petit pour avoir des résultats pertinents. De plus, le choix de pouvoir détecter les aliments à partir d'une vidéo (ou webcam) n'est pas pertinent, on n'a pas besoin de sacrifier la performance pour augmenter le temps de calcul.

Création d'un dataset personnalisé

J'ai extrait environ 15 classes du dataset Food101, en choisissant celles qui avaient beaucoup de chance de contenir d'autres classes dans leurs images, afin de gagner du temps de scrapping et de labelisation (ex: burger, ketchup et fries souvent ensemble).

De plus, j'ai scrappé Google Images pour obtenir des classes personnalisées comme "salad", "ketchup" ou "bread" à l'aide de l'outil de téléchargement Bulk Image Downloader.

J'ai donc obtenu environ 1900 images pour 19 classes, soit plus ou moins 100 images par classe. J'ai ensuite redimensionné celles-ci en format 250x250 pixels.

```
>>> df.count
<bound method DataFrame.count of                filename  width  height  xmin  ymin  xmax  ymax
class
apple_pie             300    300     300   300   300   300   300
beer                    1      1       1     1     1     1     1
bolonese_pasta        112    112     112   112   112   112   112
bread                 169    169     169   169   169   169   169
burger                340    340     340   340   340   340   340
carbonara              89     89      89    89    89    89    89
carbonara_pasta         2      2       2     2     2     2     2
chantilly              53     53      53    53    53    53    53
coffee                  1      1       1     1     1     1     1
cream                   3      3       3     3     3     3     3
fires                   2      2       2     2     2     2     2
fries                 383    383     383   383   383   383   383
hotdog                122    122     122   122   122   122   122
icecream              515    515     515   515   515   515   515
ketchup               102    102     102   102   102   102   102
omelette              323    323     323   323   323   323   323
pie                     2      2       2     2     2     2     2
potatoes                1      1       1     1     1     1     1
rice                  290    290     290   290   290   290   290
salad                 161    161     161   161   161   161   161
sandwich                1      1       1     1     1     1     1>
>>> len(df.index)
21
```

Annotation du dataset avec l'outil LabelImg au format PascalVOC.

Mise en place d'une VM AWS

Suite à de nombreux problèmes dans l'installation et configuration des outils de compilation de Tensorflow et de Python sous Windows, j'ai décidé de migrer sous Linux. J'ai donc mis en place une VM chez Amazon Web Services. VM de type g3.4xlarge, optimisée pour les calculs GPU (16 coeurs, 47 ECU et 122Gio de mémoire). Ensuite mise en place des dépendances et de Tensorflow.

Formattage & Répartition des données

- Transfert du dataset vers l'instance AWS

```
scp -i <key_path> -r <user>@<server> <local_path>
```

- Convertion des annotations du format PascalVOC vers un format CSV

```
python voc_to_csv.py
```

- Mise en place d'un script de séparation des ensembles de test et d'entrainement

```
python labels_test_train_split.py
```

- Compilation du dataset en un fichier tfrecord, à réaliser deux fois pour les subsets d'entrainement et de test.

```
python generate_tfrecord.py
```

- Création du fichier de mappage des classes

Modèle

On utilise la méthode du transfer learning pour initialiser notre modèle à partir d'un modèle pré-entrainé sur des énormes quantités de données.

Nous avons le choix entre les modèles "légers" et plus "approximatifs", et des modèles plus lents et "précis". J'ai choisi la seconde catégorie suite à ma première expérience décrite plus haut. Le modèle est inception v2 entrainé sur le dataset Coco. On a fait le choix de reconnaitre le bon aliment en plus de temps de calcul.

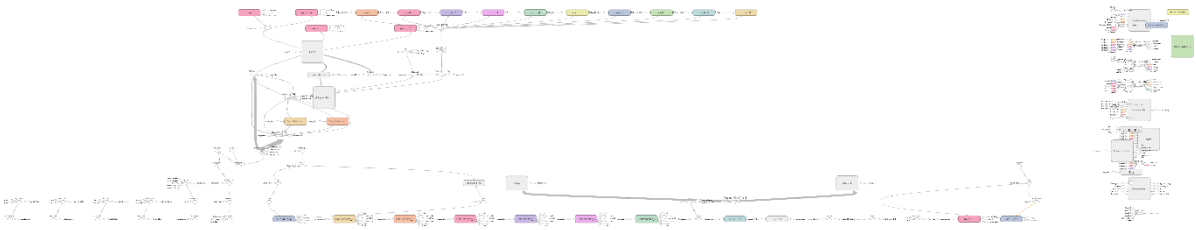

Installation

- On clone le projet à partir du GitHub de Tensorflow
- On l'intègre à notre projet et on configure le pipeline

Entrainement

On lance l'entrainement

```
python ../object_detection/model_main.py \
    --pipeline_config_path=training/inception_v2.config \
    --model_dir=resulting_model/ \
    --num_train_steps=50000 \
    --sample_1_of_n_eval_examples=1 \
    --alsologtostderr
```

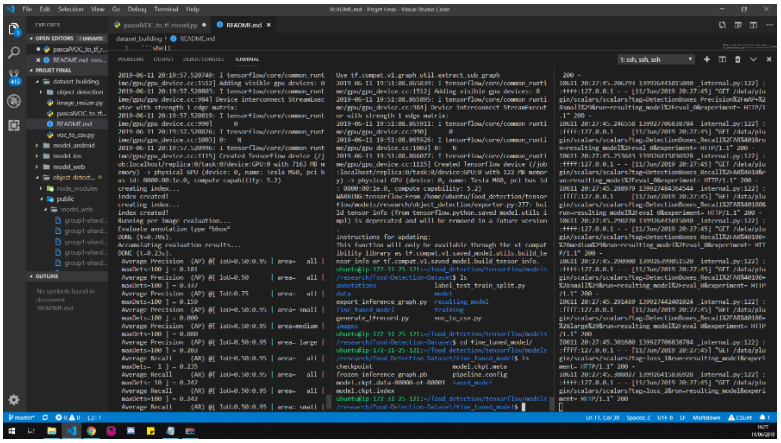

On supervise l'entrainement avec TensorBoard (évaluation jobs).

```
ssh -L 127.0.0.1:<remote_port>:127.0.0.1:<local_port> <user>@<server>
cd path/to/project
tensorboard log_dir=.
```

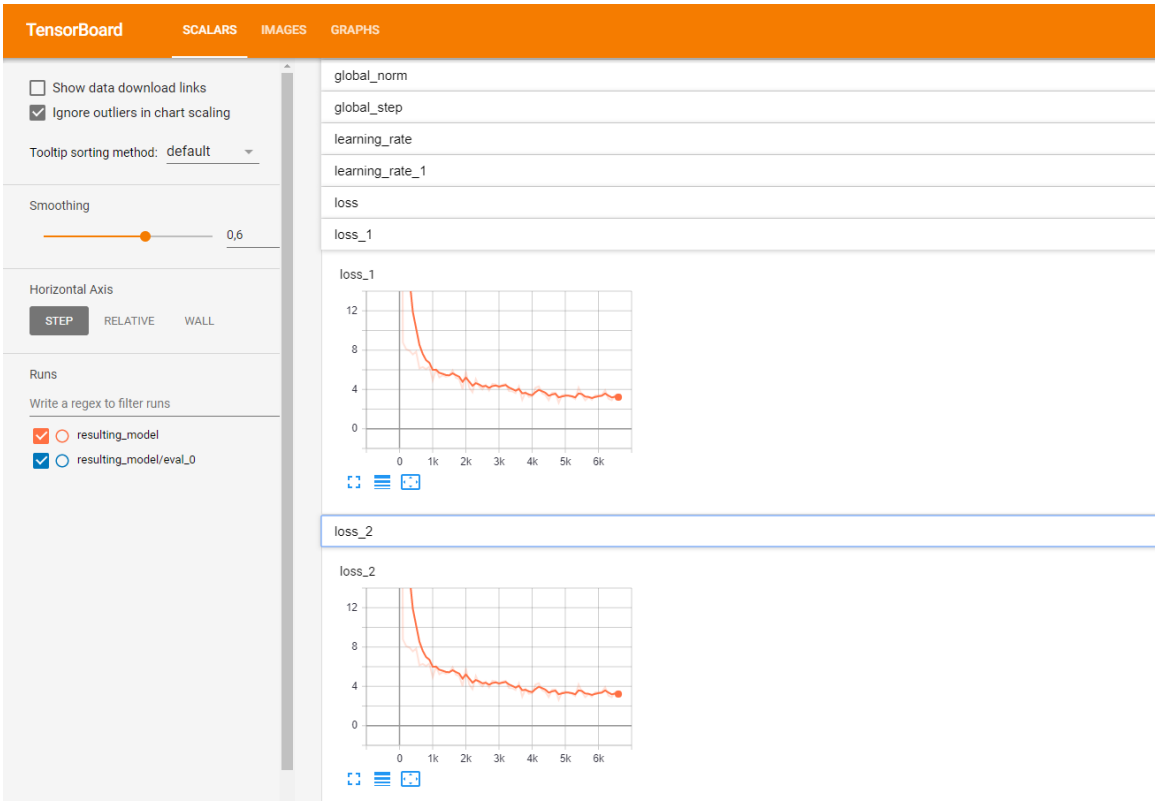

Enfin on sauvegarde le model en tant que fichier .pb.

```
python export_inference_graph.py \
      --input_type image_tensor \
      --pipeline_config_path training/inception_v2.config \
      --trained_checkpoint_prefix resulting_model/model.ckpt-2406
      --output_directory ./fine_tuned_model
```

Planification

- Script de conversion du modèle du format .pb à JSON pour l'utiliser sur le web en NodeJS (avec Tensorflow JS)
- Modifier l'application "démo" pour pouvoir tester sur des images et non sur la webcam le nouveau modèle.

- Réiterer la recherche du meilleur modèle sur lequel réentrainer
- Optimisation du modèle choisi
- Mise en place d'une API servant notre modèle
- Refactor l'architecture du projet pour respecter les bonnes pratiques
- Ajouter des classes à reconnaitre

Bilan

J'ai rencontré beaucoup de difficultés à mettre en place un environnement de travail sous Windows, de plus la création d'un dataset est un processus très long et répétitif.

J'ai pris beaucoup de plaisir à mettre en place un dataset unique, et à le coupler à un modèle de Deep Learning. De plus, malgré beaucoup d'optimisations possibles, le modèle reconnait déjà ses premières images.

Annexes

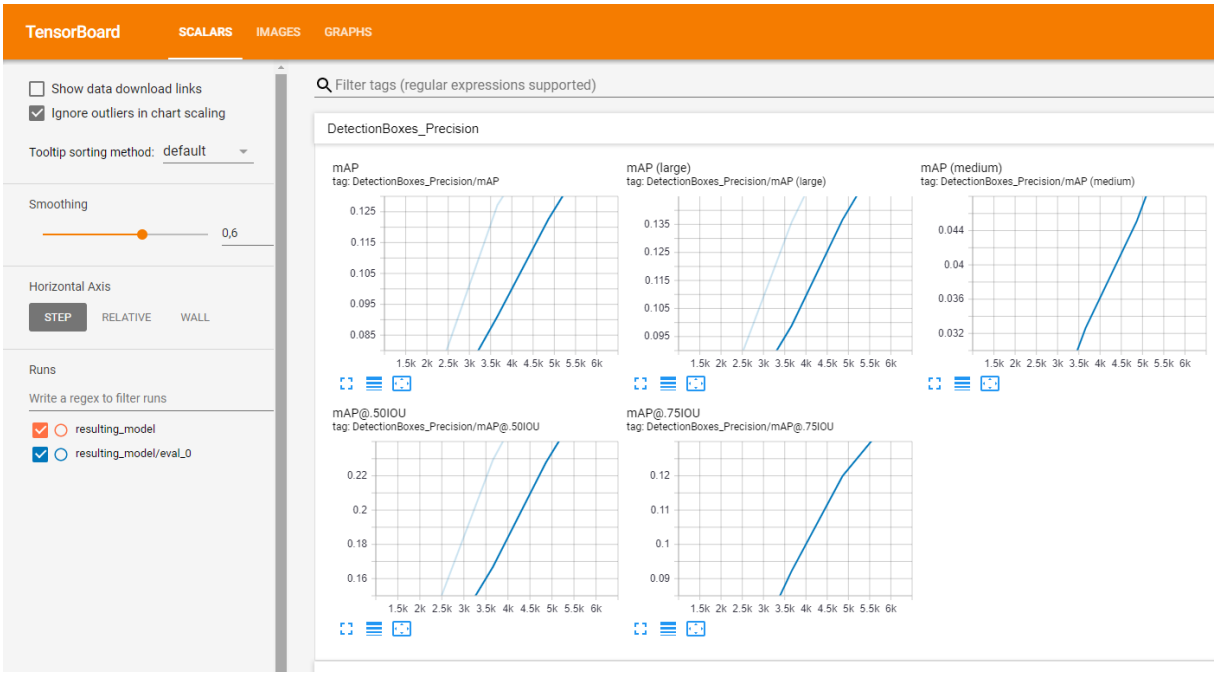

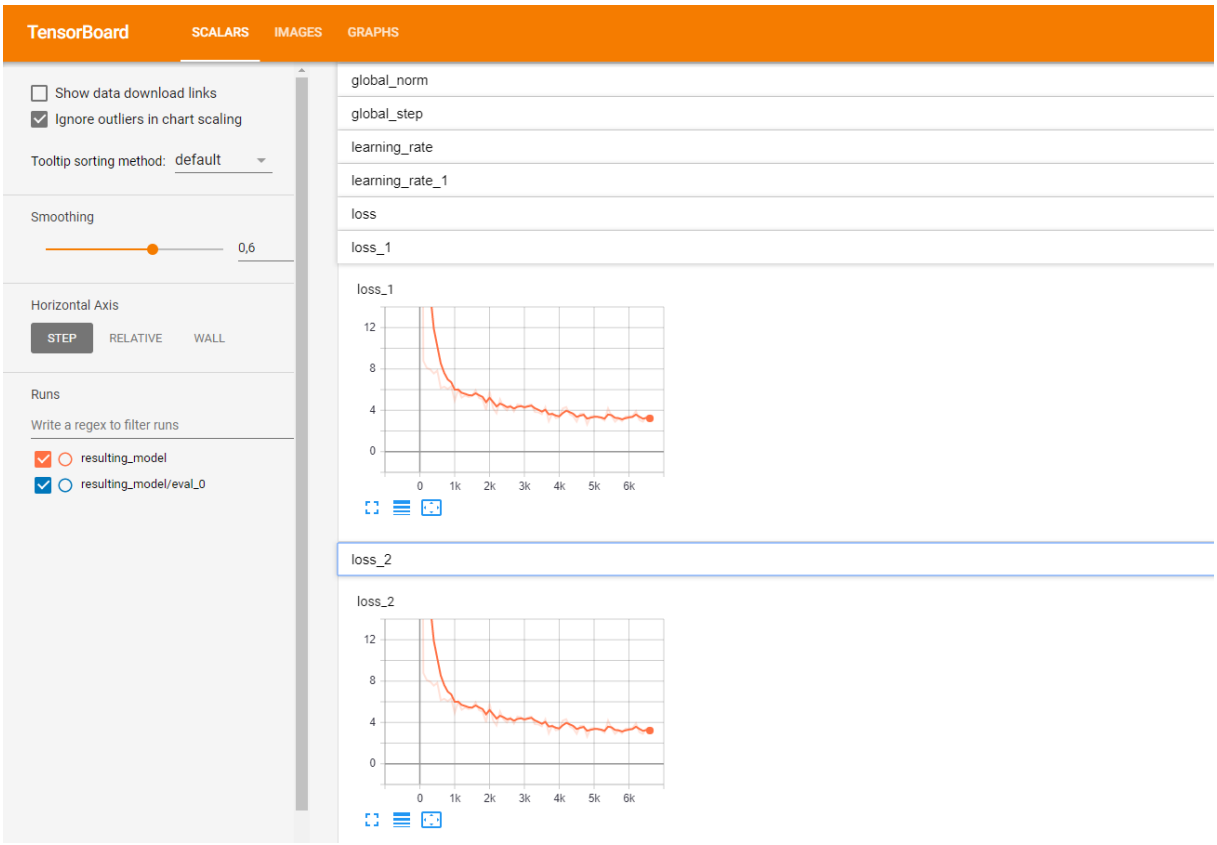

Figure 1: Capture d'écran de TensorBoard

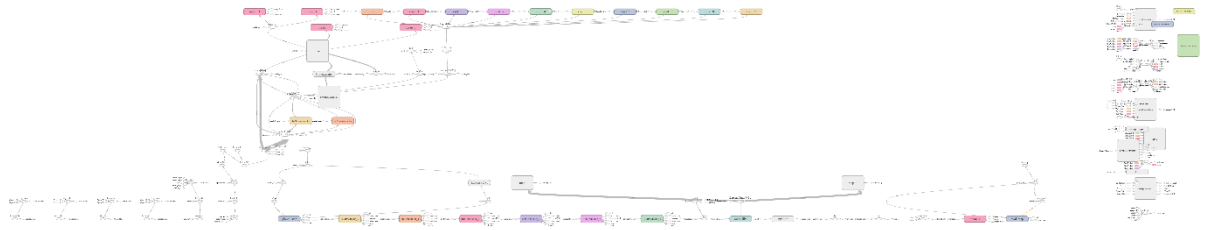

Figure 2: Graph d'Inception v2

```
>>> df.count
<bound method DataFrame.count of                 filename  width  height  xmin  ymin  xmax  ymax
class
apple_pie              300    300     300   300   300   300   300
beer                     1      1       1     1     1     1     1
bolonese_pasta         112    112     112   112   112   112   112
bread                  169    169     169   169   169   169   169
burger                 340    340     340   340   340   340   340
carbonara               89     89      89    89    89    89    89
carbonara_pasta          2      2       2     2     2     2     2
chantilly               53     53      53    53    53    53    53
coffee                   1      1       1     1     1     1     1
cream                    3      3       3     3     3     3     3
fires                    2      2       2     2     2     2     2
fries                  383    383     383   383   383   383   383
hotdog                 122    122     122   122   122   122   122
icecream               515    515     515   515   515   515   515
ketchup                102    102     102   102   102   102   102
omelette               323    323     323   323   323   323   323
pie                      2      2       2     2     2     2     2
potatoes                 1      1       1     1     1     1     1
rice                   290    290     290   290   290   290   290
salad                  161    161     161   161   161   161   161
sandwich                 1      1       1     1     1     1     1>
>>> len(df.index)
21
```

Figure 3: Capture d'écran des différentes classes

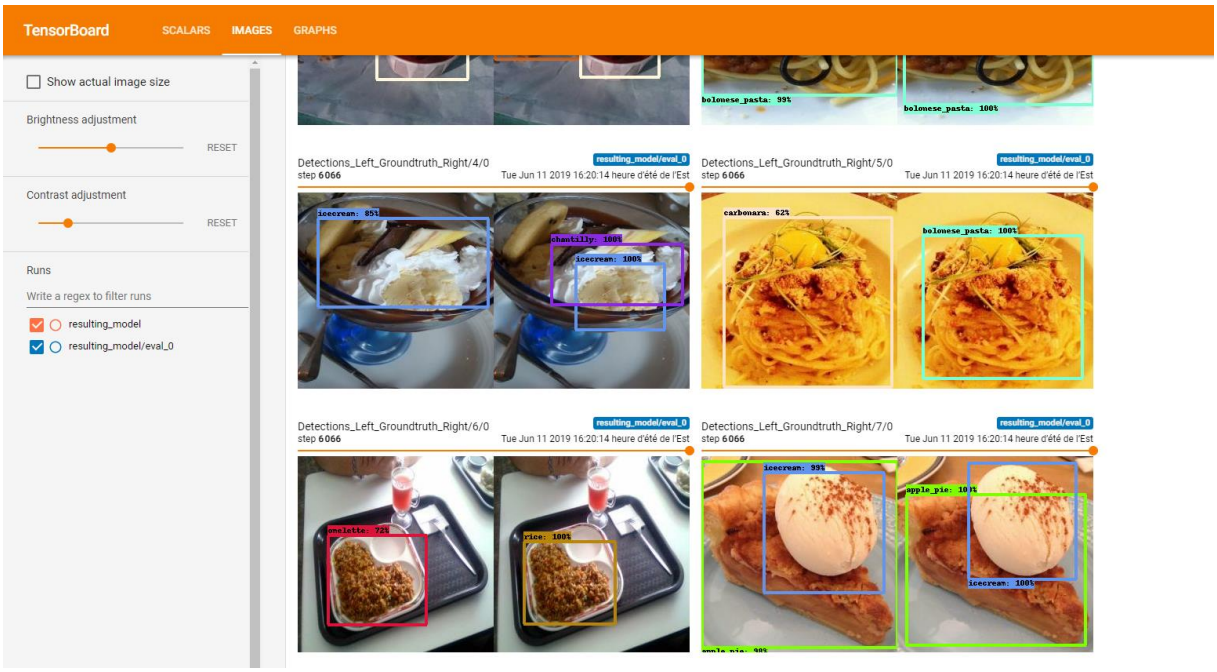

Figure 4: Exemples de prédictions vs annotations

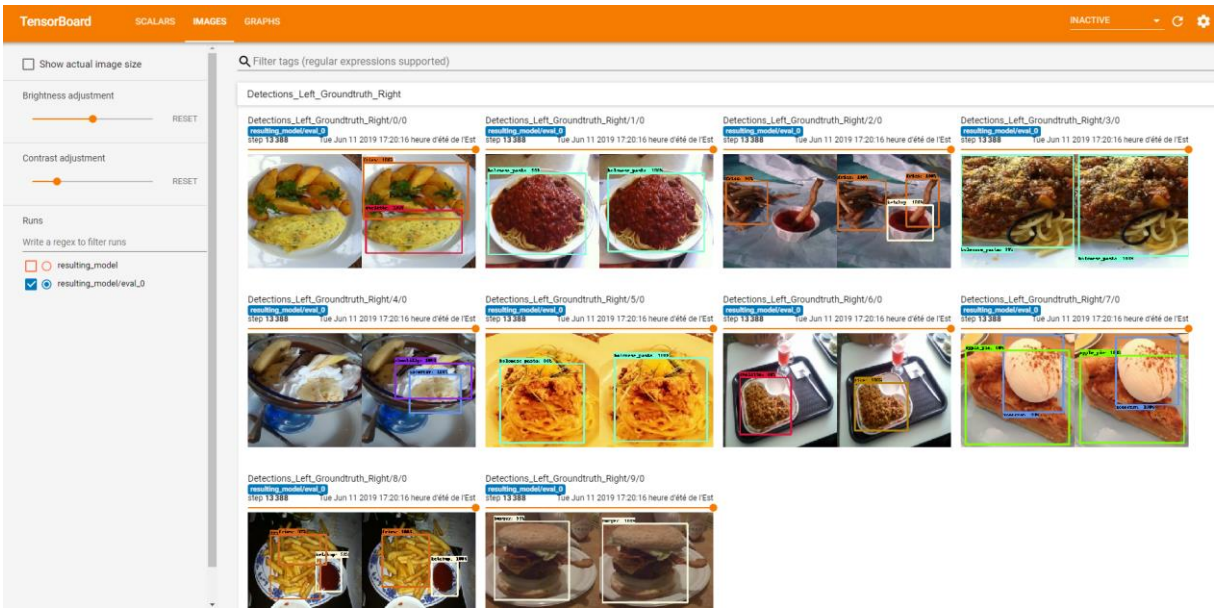

Figure 5: Exemples de prédictions vs annotations

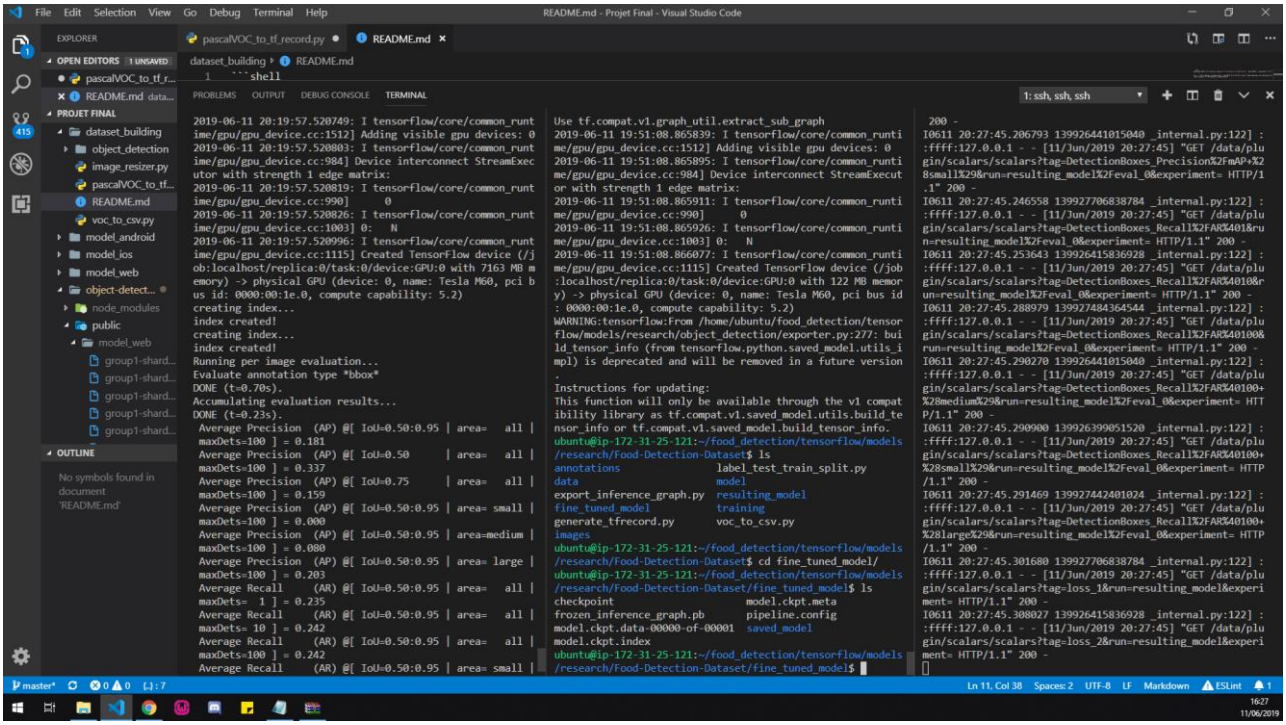

Figure 6: différents terminaux servant à lancer et monitorer l'entrainement du modèle